PROYECTO ACA 1 · APRENDIZAJE AUTOMÁTICO · PILAR SALUD

CardioPredict AI

Tamizaje de riesgo de cardiopatía con Machine Learning clásico

Especialización en Inteligencia Artificial · CUN · **Docente:** Dr. Hamilton Rivera Flor
Autora: Claudia Teresa Aranguren Peña

APRENDIZAJE AUTOMÁTICO/54ES2/SEGUNDO BLOQUE/26ES4

1 · Objetivo general

Desarrollar un modelo de clasificación supervisada con algoritmos clásicos que estime el riesgo de cardiopatía a partir de 13 biomarcadores clínicos, y desplegarlo como herramienta interactiva de tamizaje en Streamlit.

2 · Pregunta orientadora

¿Es posible identificar a pacientes con riesgo de cardiopatía a partir de biomarcadores clínicos de rutina, para priorizar exámenes confirmatorios y reducir los casos que pasan sin detectar?

3 · Pilar y dataset

Salud: detección asistida de enfermedades.
UCI Heart Disease (Cleveland): 303 pacientes, 13 variables clínicas y objetivo binario: 54.1 % sanos · 45.9 % con cardiopatía. Solo 6 datos faltantes (0.14 %).

4 · Ruta de aprendizaje: flujo metodológico

① EDA
Distribuciones, balance de clases y análisis bivariado frente al diagnóstico.

② Limpieza
Partición 80/20 primero; pipeline con imputación, escalado y One-Hot, sin fuga.

③ Modelado
Regresión Logística, Random Forest y KNN con GridSearchCV y validación cruzada.

④ Evaluación
Criterio fijado antes: ROC-AUC. Umbral elegido en validación; test usado una vez.

⑤ Despliegue
App en Streamlit Cloud que lee el modelo y las métricas reales.

5 · Métricas · Regresión Logística

Validación cruzada (5 particiones, umbral 0.5): estimación más representativa

ROC-AUC	ACCURACY	RECALL	PRECISION
0.907 ± 0.018	0.839 ± 0.016	0.766 ± 0.045	0.877 ± 0.071

Conjunto de prueba (61 pacientes, umbral 0.25): evaluación única

RECALL	ESPECIFICIDAD	PRECISION	ROC-AUC
1.000	0.697	0.737	0.958
28 / 28	23 / 33	28 / 38	prueba

Con solo 28 enfermos en la prueba, el Recall de 1.000 tiene un IC 95 % aproximado de 0.88 a 1.00: no implica que el modelo nunca falle.

6 · Comparación (ROC-AUC, validación cruzada)

Regresión Logística ✓ seleccionado	**0.907 ± 0.018**
Random Forest	0.901 ± 0.023
KNN	0.890 ± 0.022

Desempeños equivalentes: se eligió el más simple, interpretable y con menor sobreajuste.

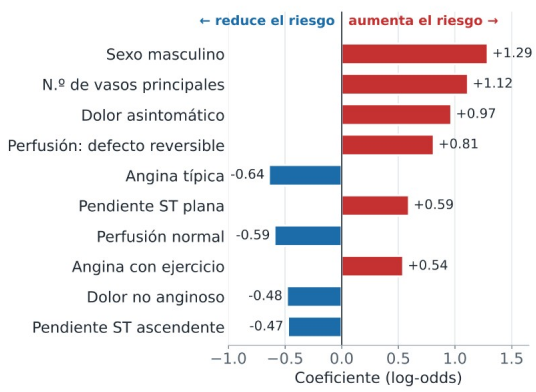
7 · Umbral clínico: 0.25

Elegido en validación cruzada para Recall ≥ 0.90 (logró 0.910; precisión 0.697): menos enfermos sin detectar, a costa de ≈3 falsas alarmas por cada 10 alertas.

Matriz de confusión · prueba

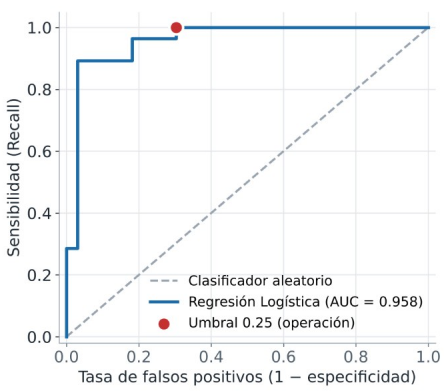
23 VN	10 FP
0 FN	28 VP

8 · ¿Qué aprendió el modelo? Coeficientes principales

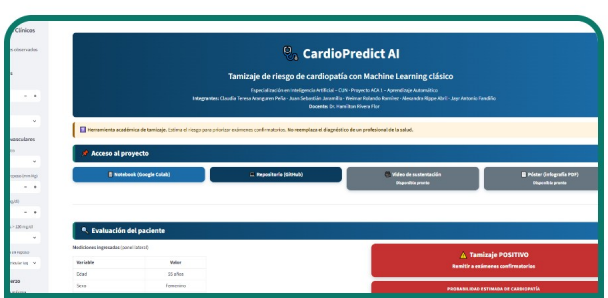


En resumen: ser hombre, tener más vasos afectados, dolor asintomático o un defecto de perfusión reversible son las señales que más elevan el riesgo; la angina típica y la perfusión normal lo reducen.

9 · Curva ROC en el conjunto de prueba



En resumen: la curva se aleja de la diagonal (AUC 0.958), así que el modelo separa bien sanos y enfermos. El punto rojo es donde opera: detectó a todos los enfermos de la prueba.



10 · App en vivo: clic para abrirla ↗

11 · Acceso al proyecto: clic en cada enlace ↗

App Streamlit · cardiopredict-ai-ctap.streamlit.app

Notebook	Código	Video
Google Colab	GitHub	YouTube

12 · Conclusión

Útil como **herramienta de tamizaje** para priorizar exámenes. **No reemplaza el diagnóstico médico.** Limitación: muestra pequeña de un solo centro; son asociaciones, no causas.

Referencias (APA 7)

Janosi, A., Steinbrunn, W., Pfisterer, M., & Detrano, R. (1988). *Heart disease* [Conjunto de datos]. UCI Machine Learning Repository. https://doi.org/10.24432/C52P4X

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research, 12*, 2825–2830.