PROYECTO ACA 1 · APRENDIZAJE AUTOMÁTICO · PILAR SALUD

# CardioPredict AI

## Tamizaje de riesgo de cardiopatía con Machine Learning clásico

Corporación Unificada Nacional de Educación Superior · VIGILADA MINEDUCACIÓN

Especialización en Inteligencia Artificial · CUN · **Docente:** Dr. Hamilton Rivera Flor

**Equipo:** Claudia Teresa Aranguren Peña · Juan Sebastián Jaramillo · Weimar Rolando Ramírez · Alexandra Rippe Abril · Jayr Antonio Fandiño

### 1 · Objetivo general

Desarrollar un modelo de clasificación supervisada con algoritmos clásicos que estime el riesgo de cardiopatía a partir de 13 biomarcadores clínicos, y desplegarlo como herramienta interactiva de tamizaje en Streamlit.

### 2 · Pregunta orientadora

¿Es posible identificar a pacientes con riesgo de cardiopatía a partir de biomarcadores clínicos de rutina, para priorizar exámenes confirmatorios y reducir los casos que pasan sin detectar?

### 3 · Pilar y dataset

**Salud:** detección asistida de enfermedades. **UCI Heart Disease (Cleveland):** 303 pacientes, 13 variables clínicas y objetivo binario: 54.1 % sanos · 45.9 % con cardiopatía. Solo 6 datos faltantes (0.14 %).

### 4 · Ruta de aprendizaje: flujo metodológico

**① EDA**
Distribuciones, balance de clases y análisis bivariado frente al diagnóstico.

**② Limpieza**
Partición 80/20 primero; pipeline con imputación, escalado y One-Hot, sin fuga.

**③ Modelado**
Regresión Logística, Random Forest y KNN con GridSearchCV y validación cruzada.

**④ Evaluación**
Criterio fijado antes: ROC-AUC. Umbral elegido en validación; test usado una vez.

**⑤ Despliegue**
App en Streamlit Cloud que lee el modelo y las métricas reales.

### 5 · Métricas · Regresión Logística

**Validación cruzada (5 particiones, umbral 0.5): estimación más representativa**

| ROC-AUC | ACCURACY | RECALL | PRECISION |
|---|---|---|---|
| 0.907 ± 0.018 | 0.839 ± 0.016 | 0.766 ± 0.045 | 0.877 ± 0.071 |

**Conjunto de prueba (61 pacientes, umbral 0.25): evaluación única**

| RECALL | ESPECIFICIDAD | PRECISION | ROC-AUC |
|---|---|---|---|
| 1.000 | 0.697 | 0.737 | 0.958 |
| 28 / 28 | 23 / 33 | 28 / 38 | prueba |

Con solo 28 enfermos en la prueba, el Recall de 1.000 tiene un IC 95 % aproximado de 0.88 a 1.00: no implica que el modelo nunca falle.

### 6 · Comparación (ROC-AUC, validación cruzada)

| | |
|---|---|
| **Regresión Logística ✓ seleccionado** | **0.907 ± 0.018** |
| Random Forest | 0.901 ± 0.023 |
| KNN | 0.890 ± 0.022 |

Desempeños equivalentes: se eligió el más simple, interpretable y con menor sobreajuste.

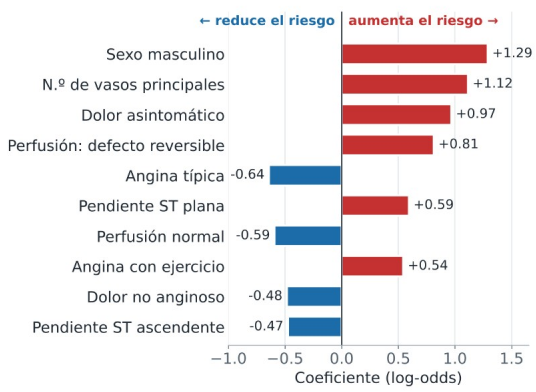
### 7 · Umbral clínico: 0.25

Elegido en validación cruzada para Recall ≥ 0.90 (logró 0.910; precisión 0.697): menos enfermos sin detectar, a costa de ≈3 falsas alarmas por cada 10 alertas.

**Matriz de confusión · prueba**

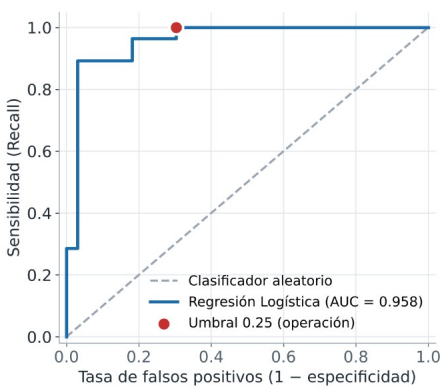
| | |
|---|---|
| 23 VN | 10 FP |
| 0 FN | 28 VP |

### 8 · ¿Qué aprendió el modelo? Coeficientes principales

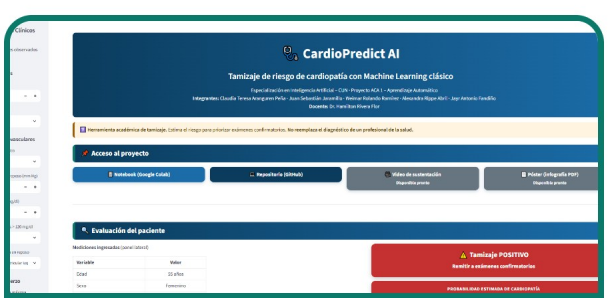



**En resumen:** ser hombre, tener más vasos afectados, dolor asintomático o un defecto de perfusión reversible son las señales que más elevan el riesgo; la angina típica y la perfusión normal lo reducen.

### 9 · Curva ROC en el conjunto de prueba




**En resumen:** la curva se aleja de la diagonal (AUC 0.958), así que el modelo separa bien sanos y enfermos. El punto rojo es donde opera: detectó a todos los enfermos de la prueba.




### 10 · App en vivo: clic para abrirla ↗

### 11 · Acceso al proyecto: clic en cada enlace ↗

**App Streamlit · cardiopredict-ai-ctap.streamlit.app**

| Notebook | Código | Video |
|---|---|---|
| Google Colab | GitHub | YouTube |

### 12 · Conclusión

Útil como **herramienta de tamizaje** para priorizar exámenes. **No reemplaza el diagnóstico médico.** Limitación: muestra pequeña de un solo centro; son asociaciones, no causas.

### Referencias (APA 7)

Janosi, A., Steinbrunn, W., Pfisterer, M., & Detrano, R. (1988). *Heart disease* [Conjunto de datos]. UCI Machine Learning Repository. https://doi.org/10.24432/C52P4X

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research, 12*, 2825–2830.