PROYECTO ACA 1 · APRENDIZAJE AUTOMÁTICO · PILAR SALUD

CardioPredict AI

Tamizaje de riesgo de cardiopatía con Machine Learning clásico

Especialización en Inteligencia Artificial · CUN · **Docente:** Dr. Hamilton Rivera Flor
Autora: Claudia Teresa Aranguren Peña

APRENDIZAJE AUTOMÁTICO/54ES2/SEGUNDO BLOQUE/26ES4

1 · Objetivo general

Desarrollar un modelo de clasificación supervisada con algoritmos clásicos que estime el riesgo de cardiopatía a partir de 13 biomarcadores clínicos, y desplegarlo como herramienta interactiva de tamizaje en Streamlit.

2 · Pregunta orientadora

¿Es posible identificar a pacientes con riesgo de cardiopatía a partir de biomarcadores clínicos de rutina, para priorizar exámenes confirmatorios y reducir los casos que pasan sin detectar?

3 · Pilar y dataset

Salud: detección asistida de enfermedades. **UCI Heart Disease (Cleveland):** 303 pacientes, 13 variables clínicas y objetivo binario: 54.1 % sanos · 45.9 % con cardiopatía. Solo 6 datos faltantes (0.14 %).

4 · Flujo metodológico: de los datos a la app

① EDA — Distribuciones, balance de clases y análisis bivariado frente al diagnóstico.

② Limpieza — Partición 80/20 primero; pipeline con imputación, escalado y One-Hot, sin fuga.

③ Modelado — Regresión Logística, Random Forest y KNN con GridSearchCV y validación cruzada.

④ Evaluación — Criterio fijado antes: ROC-AUC. Umbral elegido en validación; test usado una vez.

⑤ Despliegue — App en Streamlit Cloud que lee el modelo y las métricas reales.

5 · Métricas · Regresión Logística

Validación cruzada (5 particiones, umbral 0.5): estimación más representativa

ROC-AUC	ACCURACY	RECALL	PRECISION
0.907 ± 0.018	0.839 ± 0.016	0.766 ± 0.045	0.877 ± 0.071

Conjunto de prueba (61 pacientes, umbral 0.25): evaluación única

RECALL	ESPECIFICIDAD	PRECISION	ROC-AUC
1.000 (28 / 28)	0.697 (23 / 33)	0.737 (28 / 38)	0.958 prueba

Con solo 28 enfermos en la prueba, el Recall de 1.000 tiene un IC 95 % aproximado de 0.88 a 1.00: no implica que el modelo nunca falle.

6 · Comparación (ROC-AUC, validación cruzada)

Regresión Logística ✓ seleccionado	**0.907 ± 0.018**
Random Forest	0.901 ± 0.023
KNN	0.890 ± 0.022

Desempeños equivalentes: se eligió el más simple, interpretable y con menor sobreajuste.

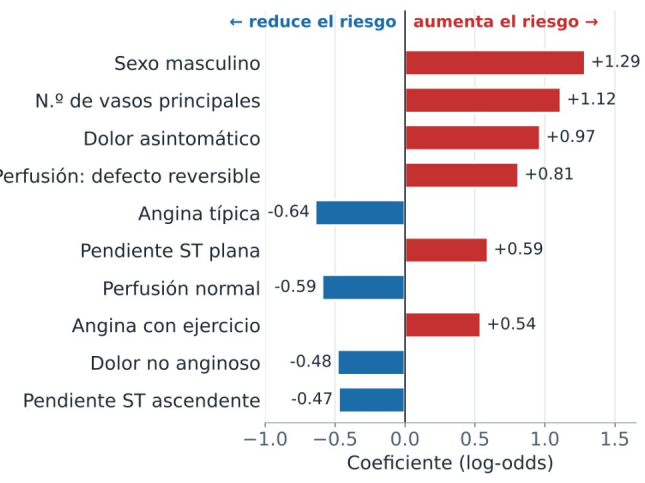
7 · Umbral clínico: 0.25

Elegido en validación cruzada para Recall ≥ 0.90 (logró 0.910; precisión 0.697): menos enfermos sin detectar, a costa de ≈3 falsas alarmas por cada 10 alertas.

Matriz de confusión · prueba

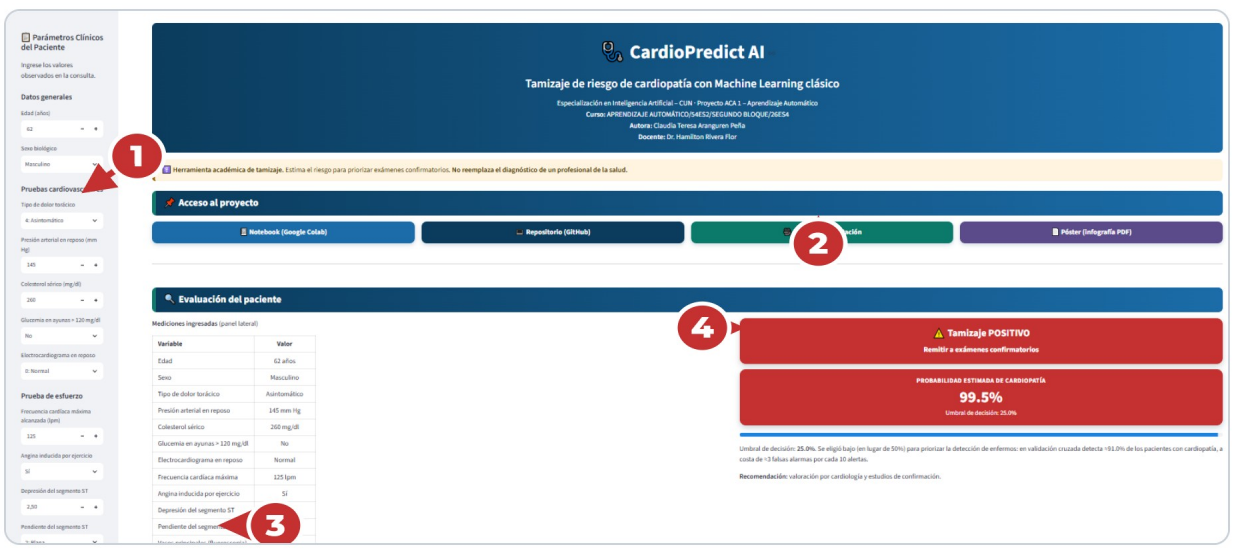
23 VN	10 FP
0 FN	28 VP

8 · ¿Cómo decide el modelo?



La **Regresión Logística** suma el peso de cada variable y lo convierte en una probabilidad de 0 a 100 %. Elevan el riesgo: ser hombre, más vasos afectados, dolor asintomático y defecto de perfusión reversible.

9 · La aplicación en acción: así se usa (abrir app ↗)



1 **Barra lateral:** se ingresan los datos clínicos

2 **Enlaces:** notebook, código, video y póster

3 **Analizar riesgo cardíaco:** ejecuta el modelo

4 **Resultado:** probabilidad y decisión (umbral 25 %)

10 · Acceso: clic en cada enlace ↗

App	Notebook	Código	Video
Streamlit	Colab	GitHub	YouTube

11 · Conclusiones

Hallazgos: un modelo simple y explicable (Regresión Logística) igualó a Random Forest (ROC-AUC 0.907 frente a 0.901), y bajar el umbral a 0.25 subió la detección de enfermos de 0.77 a 0.91 en validación. **Uso:** tamizaje para priorizar exámenes; **no reemplaza el diagnóstico médico. Limitación:** 303 pacientes de un solo centro.

Referencias (APA 7)

Janosi, A., Steinbrunn, W., Pfisterer, M., & Detrano, R. (1988). *Heart disease* [Conjunto de datos]. UCI Machine Learning Repository. https://doi.org/10.24432/C52P4X

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research, 12*, 2825–2830.